

Análise por Simulação de Eventos Discretos de uma Fila M/M/1 com Clientes Impacientes e Retentativas

José Antonio García Ocaña
Instituto Nacional de Telecomunicações (Inatel)
Santa Rita do Sapucaí, MG, Brasil
jose.ocana@mtel.inatel.br

Alfredo Jesús Arbolaes Fundora
Instituto Nacional de Telecomunicações (Inatel)
Santa Rita do Sapucaí, MG, Brasil
alfredo.arbolaes@dtel.inatel.br

Resumo—Este trabalho apresenta a modelagem e a análise, via simulação de eventos discretos, de um sistema de suporte técnico modelado como uma fila M/M/1 com clientes impacientes e retentativas (*retrial queue with balking*). No modelo proposto, um cliente que encontra mais de N usuários na fila abandona o sistema com probabilidade p ou retorna, após um tempo exponencial de média $1/\gamma$, com probabilidade $1 - p$, podendo tentar diversas vezes. O simulador foi validado contra os resultados analíticos da fila M/M/1 clássica (erro relativo máximo de aproximadamente 2%). Os experimentos quantificam o impacto do limiar N , da probabilidade de abandono p e da taxa de retorno γ sobre a probabilidade de perda, o tempo médio no sistema e a ocupação da órbita. Os resultados mostram que o mecanismo de impaciência atua como um controle de admissão natural e, nos cenários simulados, mantém finitos o tempo médio no sistema e a ocupação média da órbita mesmo sob sobrecarga ($\lambda \geq \mu$), regime em que a fila M/M/1 clássica é instável.

Index Terms—Teoria de filas, simulação de eventos discretos, filas com retentativas, clientes impacientes, M/M/1, controle de admissão.

I. INTRODUÇÃO

Sistemas de atendimento com recursos limitados raramente atendem todos os clientes de forma imediata. Em centrais de suporte técnico, redes de acesso aleatório e servidores web, é comum que um usuário, ao encontrar o sistema congestionado, decida *desistir* do atendimento ou *tentar novamente mais tarde*. Esses comportamentos, conhecidos respectivamente como *balking* e *retrial*, alteram de forma significativa o desempenho do sistema e não são capturados pelos modelos de fila clássicos [1].

As filas com retentativas (*retrial queues*) modelam justamente os cenários em que clientes bloqueados não são perdidos imediatamente, mas migram para um conjunto virtual denominado *órbita*, de onde reenviam pedidos de atendimento após intervalos aleatórios [2]. Esse paradigma descreve fenômenos como rechamadas em *call centers*, o Canal de Acesso Aleatório (*Random Access Channel* – RACH) em redes celulares e as retransmissões em protocolos do tipo ALOHA.

Neste estudo de caso considera-se um sistema de suporte técnico com um único atendente. As chegadas seguem um processo de Poisson de taxa λ e os tempos de serviço são exponenciais de média $1/\mu$. A novidade do modelo está na política de admissão: um cliente que encontra *mais de* N usuários na fila torna-se impaciente e, com probabilidade p , abandona o sistema; com probabilidade $1 - p$, entra em órbita

e retorna após um tempo exponencial de média $1/\gamma$, repetindo o processo quantas vezes forem necessárias.

O restante do artigo está organizado da seguinte forma. A Seção II descreve a modelagem do sistema, incluindo as variáveis de estado, as entidades, os eventos e a metodologia de simulação. A Seção III apresenta a validação do simulador e os resultados dos experimentos. A Seção IV resume as principais conclusões.

II. MODELAGEM DO SISTEMA

A. Descrição e Notação

O sistema possui um único servidor, disciplina *First Come, First Served* (FCFS) e capacidade de armazenamento considerada ilimitada; entretanto, a entrada de clientes na fila é controlada pela política de impaciência. A Tabela I resume os parâmetros do modelo.

Tabela I
PARÂMETROS DO MODELO.

Símbolo	Significado
λ	Taxa de chegada (Poisson)
μ	Taxa de serviço (exponencial), média $1/\mu$
N	Limiar da fila para impaciência
p	Probabilidade de abandono imediato (<i>balking</i>)
γ	Taxa de retorno da órbita, média $1/\gamma$

B. Variáveis de Estado

O estado do sistema em cada instante t é descrito por:

- t : relógio da simulação (*CLOCK*);
- $L_q(t)$: número de clientes na fila de espera;
- $L_s(t)$: estado do servidor, com $L_s = 1$ (ocupado) ou $L_s = 0$ (livre);
- $L(t) = L_q(t) + L_s(t)$: número de clientes no sistema, desconsiderando os clientes na órbita;
- $orbit(t)$: número de clientes na órbita aguardando retentar.

C. Entidades

As entidades do modelo são: os **clientes** (cada um carrega o instante de sua primeira chegada e o número de retentativas já realizadas), o **servidor** único, a **fila de espera** (*buffer* com disciplina *First In, First Out* (FIFO)) e a **órbita**, conjunto dos clientes que optaram por retornar.

D. Eventos

A dinâmica é governada por três tipos de evento:

- **Chegada (A):** um novo cliente chega do fluxo de Poisson;
- **Partida (D):** conclusão de um atendimento;
- **Retentativa (R):** um cliente da órbita retorna para tentar novamente.

A regra de admissão, aplicada tanto às chegadas quanto às retentativas, é a mesma: se $L_q \leq N$, o cliente é admitido (inicia serviço se o servidor estiver livre ou entra na fila caso contrário); se $L_q > N$, o cliente torna-se impaciente e abandona com probabilidade p ou agenda uma retentativa com probabilidade $1-p$. As Figuras 1 e 2 ilustram, respectivamente, os fluxogramas dos eventos de chegada/retentativa e de partida.




Figura 1. Fluxograma do evento de chegada e de retentativa.




Figura 2. Fluxograma do evento de partida.

E. Métricas e Metodologia

As médias temporais são obtidas integrando as variáveis de estado ao longo do tempo. Para um horizonte total T , o número médio na fila e em órbita são

$$E[L_q] = \frac{1}{T} \int_0^T L_q(t) dt, \quad E[\text{orbit}] = \frac{1}{T} \int_0^T \text{orbit}(t) dt, \quad (1)$$

e a utilização do servidor é $\rho = \frac{1}{T} \int_0^T L_s(t) dt$. O número médio de clientes no sistema, desconsiderando a órbita, é dado por $E[L] = E[L_q] + \rho$, o tempo médio no sistema $E[W]$ é calculado como a média de $t_{\text{partida}} - t_{\text{primeira chegada}}$ sobre os clientes atendidos, e a probabilidade de abandono P_{ab} é a fração de clientes distintos que abandonam definitivamente.

O simulador foi implementado em Python utilizando uma lista de eventos (*heap*) ordenada por tempo, pois a presença de múltiplos clientes em órbita, cada um com seu próprio temporizador de retorno, exige o agendamento simultâneo de vários eventos futuros. O código completo e comentado é apresentado no repositório do GitHub [3].

III. RESULTADOS

Salvo indicação em contrário, os experimentos utilizam $\lambda = 8$ e $\mu = 10$ (logo $\rho_0 = 0,8$), com horizonte de $1,2 \times 10^5$ clientes atendidos por ponto.

A. Validação do Modelo

Para validar o simulador, configurou-se $N \rightarrow \infty$ e $p = 0$, situação em que nenhum cliente fica impaciente e o sistema se reduz a uma fila M/M/1 clássica. A Tabela II compara os valores simulados com as expressões analíticas $E[L] = \rho/(1-\rho)$ e $E[W] = 1/(\mu - \lambda)$, observando-se erro relativo máximo de aproximadamente 2%.

Tabela II
VALIDAÇÃO CONTRA A FILA M/M/1 ($\lambda = 8$, $\mu = 10$).

Métrica	Simulado	Teórico
ρ	0,8032	0,8000
$E[L]$	4,0815	4,0000
$E[W]$	0,5069	0,5000

B. Experimento 1: Efeito do Limiar N

A Figura 3 e a Tabela III mostram o efeito de N com $p = 0,4$ e $\gamma = 2,0$. Quanto maior a tolerância da fila, menor a probabilidade de abandono, porém maiores o tempo médio no sistema e o número médio de clientes $E[L]$, caracterizando um *trade-off* de projeto. Por outro lado, a ocupação média da órbita diminui, pois menos clientes precisam recorrer à retentativa.

C. Experimento 2: Efeito da Probabilidade p

A Figura 4 e a Tabela IV apresentam o efeito de p com $N = 3$ e $\gamma = 2,0$. Para p baixo, quase todos os clientes impacientes retornam: a perda efetiva é pequena, mas a órbita cresce expressivamente (carga “escondida” que volta a pressionar o servidor). À medida que p aumenta, a órbita encolhe ao custo de uma maior perda definitiva de clientes.




Figura 3. Compromisso entre abandono e tempo no sistema em função de N .

Tabela III
DESEMPENHO EM FUNÇÃO DE N ($p = 0,4$, $\gamma = 2,0$).

N	P_{ab}	$E[W]$	$E[L]$	$E[\text{orbit}]$
0	0,1784	0,2793	0,9812	1,0597
1	0,1185	0,2846	1,3901	0,7298
2	0,0805	0,2917	1,7287	0,4830
3	0,0594	0,3130	2,0448	0,3616
4	0,0458	0,3346	2,3316	0,2754
5	0,0351	0,3566	2,5752	0,2193
6	0,0257	0,3696	2,7286	0,1549
8	0,0147	0,3980	3,0515	0,0916
10	0,0100	0,4310	3,3516	0,0558




Figura 4. Abandono efetivo (esq.) e tamanho da órbita (dir.) em função de p .

Tabela IV
DESEMPENHO EM FUNÇÃO DE p ($N = 3$, $\gamma = 2,0$).

p	P_{ab}	$E[W]$	$E[\text{orbit}]$
0,0	0,0000	0,5186	1,7015
0,1	0,0254	0,3959	0,9140
0,2	0,0399	0,3520	0,6302
0,3	0,0520	0,3353	0,4915
0,5	0,0666	0,2987	0,2579
0,7	0,0772	0,2773	0,1329
0,9	0,0873	0,2634	0,0400
1,0	0,0858	0,2544	0,0000

D. Experimento 3: Efeito da Taxa de Retorno γ

A Figura 5 e a Tabela V mostram o efeito de γ com $N = 3$ e $p = 0,3$. Retentativas mais rápidas (maior γ) esvaziam a órbita, mas, ao concentrar as re-chegadas, elevam ligeiramente a probabilidade de abandono efetivo. Retentativas lentas mantêm muitos clientes “estacionados” por mais tempo na órbita.




Figura 5. Efeito de γ : órbita (verde) e abandono (vermelho).

Tabela V
DESEMPENHO EM FUNÇÃO DE γ ($N = 3$, $p = 0,3$).

γ	P_{ab}	$E[W]$	$E[\text{orbit}]$
0,25	0,0398	0,6343	2,8968
0,50	0,0413	0,4606	1,5167
1,00	0,0444	0,3755	0,8340
2,00	0,0535	0,3334	0,4846
4,00	0,0608	0,3109	0,2918
8,00	0,0655	0,2876	0,1529
16,00	0,0720	0,2759	0,0825

E. Experimento 4: Comparação entre Sistemas

Compara-se a fila proposta ($p = 0,3$) com três sistemas de referência, variando λ com $\mu = 10$ e $N = 3$: a fila M/M/1 clássica ($N \rightarrow \infty$), a fila de *perda pura* ($p = 1$, sem retorno) e a fila de *retentativa pura* ($p = 0$, sem abandono). Esses dois extremos delimitam o comportamento do modelo proposto, que opera para $0 < p < 1$. A Figura 6 e a Tabela VI resumem os resultados.

A fila M/M/1 clássica torna-se instável ($E[W] \rightarrow \infty$) para $\lambda \geq \mu$. A retentativa pura nunca perde clientes (Fig. 6(a)), porém sua órbita cresce sem limite ao se aproximar de $\lambda = \mu$ (Fig. 6(c)), o que faz seu tempo no sistema também divergir (Fig. 6(b)): manter todos os clientes via retorno, sem descartar nenhum, não estabiliza o sistema em sobrecarga. Já a perda pura é sempre estável, mas descarta a maior fração de clientes. A fila proposta posiciona-se entre os dois extremos: perde menos que a perda pura e, nos cenários simulados, mantém finitos o tempo médio no sistema e a ocupação da órbita para $\lambda \geq \mu$. Os resultados indicam que o descarte efetivo de parte da carga contribui para evitar o crescimento não limitado da órbita em sobrecarga; apenas adiar os clientes por meio de retentativas não é suficiente.




Figura 6. Comparação dos quatro sistemas em função de λ ($\mu = 10$, $N = 3$, $\gamma = 2$): (a) perda; (b) tempo médio no sistema; (c) órbita. A retentativa pura ($p = 0$) apresenta crescimento não limitado da órbita para $\lambda \geq \mu$.

Tabela VI

COMPARAÇÃO ENTRE SISTEMAS ($\mu = 10$, $N = 3$, $\gamma = 2$). “INST.” INDICA CRESCIMENTO NÃO LIMITADO DA ÓRBITA DEVIDO À AUSÊNCIA DE ABANDONO.

λ	M/M/1	Perda ($p=1$)		Retent. ($p=0$)		Proposta ($p=0,3$)		
	$E[W]$	P_{ab}	$E[W]$	$E[W]$	orbit	P_{ab}	$E[W]$	orbit
4,0	0,167	0,0057	0,1603	0,1672	0,0204	0,0025	0,1667	0,0121
6,0	0,250	0,0307	0,2068	0,2590	0,2235	0,0150	0,2317	0,1058
8,0	0,500	0,0904	0,2577	0,5325	1,7962	0,0506	0,3290	0,4658
9,0	1,000	0,1265	0,2792	1,0812	6,3679	0,0823	0,3960	0,8570
9,5	2,000	0,1439	0,2902	2,0947	15,9249	0,0992	0,4311	1,1162
10,0	∞	0,1681	0,2997	inst.	inst.	0,1194	0,4665	1,3965
11,0	∞	0,2059	0,3158	inst.	inst.	0,1573	0,5322	1,9994
12,0	∞	0,2517	0,3363	inst.	inst.	0,2083	0,6153	2,9134

F. Experimento 5: Efeito da Carga ρ_0

Os experimentos anteriores fixaram a carga base em $\rho_0 = \lambda/\mu = 0,8$. Como ρ_0 define o regime de operação da fila, este experimento varia λ de 2 a 9 (com $\mu = 10$ fixo), mantendo $N = 3$, $p = 0,3$ e $\gamma = 2,0$. A Figura 7 e a Tabela VII mostram que, em carga baixa ($\rho_0 \lesssim 0,4$), a fila raramente excede o limiar N e a impaciência quase não se manifesta ($P_{ab} \approx 0$, órbita desprezível): o sistema comporta-se praticamente como um M/M/1. À medida que ρ_0 cresce, tanto o abandono quanto a órbita aumentam de forma acentuada (aproximadamente exponencial), confirmando que os mecanismos de impaciência só se tornam relevantes sob carga moderada a alta. Isso indica que as conclusões dos Experimentos 1–3, obtidas em $\rho_0 = 0,8$, representam um regime em que a sintonia de N , p e γ é efetivamente importante.




Figura 7. Efeito da carga base ρ_0 sobre o abandono (vermelho) e a órbita (verde), com $N = 3$, $p = 0,3$ e $\gamma = 2,0$.

Tabela VII

DESEMPENHO EM FUNÇÃO DA CARGA ρ_0 ($\mu = 10$, $N = 3$, $p = 0,3$, $\gamma = 2,0$).

ρ_0	P_{ab}	$E[W]$	$E[\text{orbit}]$
0,2	0,0000	0,1256	0,0003
0,3	0,0007	0,1427	0,0016
0,4	0,0024	0,1655	0,0112
0,5	0,0068	0,1956	0,0412
0,6	0,0147	0,2290	0,1050
0,7	0,0302	0,2758	0,2389
0,8	0,0516	0,3312	0,4877
0,9	0,0819	0,3981	0,8744

G. Invariância sob Escalonamento Temporal das Taxas

No modelo considerado, as métricas adimensionais dependem das razões λ/μ e γ/μ , além dos parâmetros N e p , enquanto os valores absolutos das taxas determinam apenas a escala temporal. A Tabela VIII verifica essa propriedade no modelo proposto: para um mesmo $\rho_0 = 0,8$ (com γ/μ mantido constante), variar μ preserva a probabilidade de abandono e a ocupação média da órbita, enquanto o tempo médio no sistema $E[W]$ escala com $1/\mu$. Esse resultado confirma a consistência do simulador: ao escalar simultaneamente λ , μ e γ , mantendo constantes λ/μ e γ/μ , apenas a escala temporal é alterada.

Tabela VIII
INVARIÂNCIA DAS MÉTRICAS SOB ESCALONAMENTO TEMPORAL,
MANTENDO $\rho_0 = 0,8$ FIXO E $\gamma/\mu = 0,2$.

λ	μ	γ	ρ_0	P_{ab}	$E[\text{orbit}]$	$E[W]$ (ms)
8	10	2	0,8	0,0503	0,4781	332,0
16	20	4	0,8	0,0489	0,4709	165,4
24	30	6	0,8	0,0512	0,4698	109,6
40	50	10	0,8	0,0512	0,4778	65,9

IV. CONCLUSÕES

Este trabalho modelou e simulou uma fila M/M/1 com clientes impacientes e retentativas, representativa de um sistema de suporte técnico. O simulador de eventos discretos foi validado contra a M/M/1 clássica, com erro relativo máximo de aproximadamente 2%. Os experimentos permitiram quantificar três compromissos de projeto: (i) o limiar N troca abandono por tempo de espera; (ii) a probabilidade p equilibra perda definitiva contra ocupação da órbita; e (iii) a taxa de retorno γ controla a velocidade de esvaziamento da órbita em troca de um leve aumento do abandono. O Experimento 5 mostrou ainda que esses mecanismos só se tornam relevantes sob carga moderada a alta ($\rho_0 \gtrsim 0,5$), e verificou-se a invariância das métricas adimensionais sob o escalonamento simultâneo das taxas, mantendo constantes λ/μ e γ/μ . A comparação com os sistemas de referência mostrou que a impaciência atua como um controle natural de admissão. Nos cenários simulados de sobrecarga, a fila proposta manteve métricas finitas, indicando que o descarte parcial da carga evita o crescimento não limitado da órbita. A fila proposta equilibra esses extremos, perdendo menos que a perda pura ao recuperar parte dos impacientes. Como trabalho futuro, sugere-se a investigação de políticas de retentativa com *backoff* adaptativo e a extensão para múltiplos servidores (M/M/c).

REFERÊNCIAS

- [1] L. Kleinrock, *Queueing Systems, Volume 1: Theory*. Wiley, 1975.
- [2] J. R. Artalejo and A. Gómez-Corral, *Retrial queueing systems: a computational approach*. Springer, 2008.
- [3] J. A. G. Ocaña and A. J. A. Fundora, “Estudo de caso: Fila M/M/1 com clientes impacientes e retentativas,” GitHub, Jupyter Notebook, 2026, disponível em: https://github.com/jgocana/Trabalhos-TP-547/blob/master/Trabalho%20Final%20Parte%203/estudo_caso_fila_impaciente.ipynb. Acesso em: 18 jun. 2026.